

Propuesta de método para reducción de ruido speckle
considerando métrica para la preservación de bordes para
imágenes de radar de apertura sintética (SAR)
(Nota: o podríamos enfocarnos, no en preservación de bordes,
sino en evaluar con las imágenes ratio, como lo hicieron en
M-estimator)

M.Sc. Rubén Darío Vásquez Salazar
Estudiante de Doctorado en Empresa, Internet y Tecnologías de las Comunicaciones
Universidad de Las Palmas de Gran Canaria (España)

Director: Ph.D. Luis Gómez Déniz (ULPGC)
Co-Director: Ph.D. Jorge Ernesto Espinosa (PCJIC)
Tutor: Ph.D. Carlos Manuel Travieso (ULPGC)

20 de mayo de 2023

1. Introducción

En este documento se presenta el plan de investigación como parte del proceso de estudio de Doctorado en Empresa, Internet y Tecnologías de las Comunicaciones en la ULPGC. Como parte de la revisión de literatura, se ha encontrado que las imágenes de radar de apertura sintética (SAR) son de gran importancia dada su disponibilidad independientemente de la hora del día y las condiciones climáticas, por lo tanto cuenta con imágenes con una mayor accesibilidad que las imágenes ópticas. Sin embargo, dado el tipo de tecnología usada, las imágenes cuentan con un ruido denominado 'speckle', el cual es difícil de remover. Por lo tanto ha habido un sinnúmero de publicaciones que proponen diferentes métodos, desde los tradicionales locales, hasta los no locales y ahora más recientemente los basados en inteligencia artificial. Este es un tema vigente en investigación, dado que la teledetección necesita de imágenes de la más alta calidad posible para hacer las mediciones de los objetos en tierra y poder hacer unos buenos procesos de clasificación, segmentación, etc.

El presente plan de estructura de la siguiente manera. En la sección 2, se hace una revisión de los antecedentes, es decir, las diferentes publicaciones y propuestas que existen en la literatura. En la sección 3, se formula el planteamiento del problema, haciendo énfasis en lo complejo de modelar y por ende poder filtrar el ruido speckle. En la sección 4 se formula la hipótesis y posteriormente en la 5 los objetivos (general y específicos). En la sección 6 se presenta la metodología, la cual va muy articulada con el cronograma de la sección 7. Por último en las secciones 8 y 9 se presentan los recursos requeridos y resultados esperados respectivamente.

2. Antecedentes

A continuación, se presenta una revisión sistemática de la literatura alrededor de la temática principal del proyecto que se presenta, especialmente el ruido speckle. Se inicia con los procesos de filtrado que normalmente se han utilizado, los primeros de ellos locales, que actuaban teniendo en cuenta los píxeles y sus vecindades; posteriormente los filtros no locales, que modifican el valor de un píxel teniendo en cuenta otros que no necesariamente pertenecen a su vecindad; y finalmente otras propuestas,

basadas en inteligencia artificial y sus derivaciones, que han mostrado resultados prometedores y que superan en algunos casos a las otras propuestas.

2.1. Filtros locales

Este tipo de filtros son los primeros y más clásicos en la tarea de remover o reducir el ruido speckle. Los más tradicionales son el Lee y algunas versiones mejoradas: [1], [2], [3], [4], [5], [6] y [7], entre otros; Frost y algunas de sus versiones mejoradas: [8], [9], [10], [11] y en general el análisis profundo realizado para este filtro en el año 2020 [12], incluyendo sus variaciones presentadas hasta esa fecha.

En [13] se propone una modificación del filtro bilateral adaptativo, a través de un umbral adaptativo y ventana variable. Se realiza un truncado de imágenes considerando las características estadísticas buscando una similaridad fotométrica. Este método logra suavizar el ruido speckle en regiones uniformes mientras que preserva los detalles de bordes de la imagen, mostrando una mejora de más del 16 % en comparación con el filtro bilateral tradicional.

En [14] se realiza primero la aplicación de una transformación logarítmica que genera una conversión del ruido speckle de multiplicativo a aditivo y posteriormente aplica un filtro de Lee, un filtro de mediana a partir de los coeficientes entregados por una función bivariada de contracción. Los resultados documentados demuestran mejoras respecto a trabajos previos y métodos tradicionales.

En [15] se propone un filtro basado en la característica de autocorrelación espacial de la transformada rápida de Fourier en bloques (BFFT), analizando la longitud de la autocorrelación del ruido para diferentes características y luego construye una similitud entre la longitud de la autocorrelación y el periodo del ruido. Se compararon los resultados con seis métodos de filtrado tradicionales, mostrando que se reduce a la mitad la desviación estándar y se mantiene la media.

En [16] se propone un filtro de una sola toma, denominado filtro híbrido mediana-media (HM2F del inglés Hybrid Median–Mean Filter) el cual está basado en la media de filtros de mediana convencionales calculados con diferentes tamaños del kernel, realizando una combinación sinérgica. Realizan una comparación con el filtro de media tradicional, el bloque BM3D (SAR block-matching 3-D), el filtro de media no local, el filtro de transformada de Fourier de ventanas 2D y el Wiener, demostrando gran simplicidad y costo computacional en la técnica propuesta, con un desempeño constante en diferentes tipos de imágenes, con un adecuado balance entre reducción del ruido y efecto de suavizado.

2.2. Filtros no locales

Este tipo de filtros, a diferencia de los locales, reemplazan el valor de un pixel con base en cálculos de píxeles que no necesariamente tienen que estar cerca [17]. Por ejemplo, el denominado SRAD (del inglés non-local based on anisotropic diffusion) hace uso del coeficiente instantáneo de variación [18].

En [19] se propone un filtro no local muy utilizado denominado SAR-BM3D (por sus siglas en inglés de Nonlocal SAR Image Denoising Algorithm Based on LLMMSE Wavelet Shrinkage), el cual ha presentado resultados que replantearon el estado del arte, y posteriormente fue realizado de una manera más eficiente y denominado FANS (por sus siglas en inglés de Fast Adaptive Nonlocal SAR) presentó resultados similares pero con un costo computacional significativamente más bajo [?].

En [20] se propone un enfoque de filtro híbrido con procesamiento no local, el cual usa un filtro no optimizado basado en la norma Schatten- p , obteniendo resultados que superaron el estado del arte. También en [21], usando la misma norma Schatten- p , se incluyó una característica de bordes usando un modelo de regularización de variación total no convexa, el cual demostró ser capaz de remover el ruido speckle mientras preserva bordes y texturas, comparado con métodos disponibles en el estado del arte.

En [22] se propone un filtro de media no local para datos con ENL=1, el cual usa las entropías de Shannon y Rényi, a partir de la matriz de información Fisher y la varianza asintótica para estimadores de vecindad máxima. Se realiza también un test estadístico paramétrico el cual verifica si dos muestras tienen la misma entropía y así se construye una máscara de convolución con una función de activación. En los resultados obtenidos se logra una mejor PSNR, la preservación de la media y no se afectan significativamente los bordes.

En [23] se propone una técnica híbrida basada en el filtro Sigma y el de media no local, usando el principio del enfoque no local para la selección de los píxeles a filtrar, otros se descartan. En las pruebas realizadas demostraron mejores resultados que en el filtro de Lee y el Sigma mejorados, en cuanto a la reducción del ruido y conservación de detalles espaciales.

En [24] se propone un filtro de media no local que adopta tres distancias estocásticas para medir la similitud entre las muestras, a la vez que se propone una implementación eficiente para la experimentación con diferentes parámetros y configuraciones.

En [25] se propone un filtro basado en el principio de hy-potheses y una métrica basada en la prueba de razón de verosimilitud (LRT del inglés likelihood ratio test) y se analizan los resultados obteniendo métricas como SNR y SSIM.

En [26] se propone un filtro que utiliza la transformada wavelet compleja de árbol dual no diezmada (UDT-CWT del inglés Undecimated Dual-Tree Complex Wavelet Transform usando un estimador máximo a posteriori (MAP) y un filtrado basado en análisis de componentes principales (PCA) no local con agrupación de píxeles locales (LPG-PCA). Esta propuesta se compara con filtros documentados en el estado del arte, demostrando que alcanza mejor reducción de ruido en áreas homogéneas y a su vez preserva detalles de las imágenes.

2.3. Filtros basados en inteligencia artificial

La inteligencia artificial, como gran área de desarrollo, comprende otras subáreas como el aprendizaje de máquina, y ésta a su vez comprende otra subárea de especial interés para este proyecto como el aprendizaje profundo. Por tal motivo, como parte de esta revisión, se hará la diferenciación entre estos campos de conocimiento que están inmersos y relacionados entre sí.

2.3.1. Filtros basados en aprendizaje de máquina

En [27] se usa la técnica de K-NN (K-Nearest Neighbour) con el fin de modificar el filtro tradicional de Lee y mejorar su desempeño en el filtrado de imágenes SAR antes de realizar una compresión wavelet de dos dimensionas, realizando un particionado en árboles jerárquicos. Los resultados demuestran unos resultados mejorados respecto al filtro sin estas adiciones.

2.3.2. Filtros basados en aprendizaje profundo

Algunas de las técnicas más usadas y relevantes que usan aprendizaje profundo son: Generative Adversarial Networks (GAN) [28], SAR-CNN [29], MuLoG-CNN [30], DNN [31], SAR-DRN [32], KL-DNN [33], SAR-NN3D [34], SAR-RDCP [35] y MSR-Net [36].

En [37] se propone el enfoque denominado Neith CNN, el cual es un enfoque que utiliza una función de costo diseñada para preservar características, conformada por tres componentes principales de pérdida: Euclidiana, perpetua y de vecindad. En esta propuesta obtienen resultados por encima de los alcanzados en filtros de Kuan, SAR-BM3D, SARDRN y IDCNN. En [38] también se usa una función de costo modificada, en la cual se incorpora la divergencia Kullback-Leibler, enfoque que demoninan MONET (por sus siglas en inglés de Multi-Objective CNN-Based. En los resultados presentados se hace un comparativo de métricas SSIM, SNR y MSE, respecto a filtros no locales como NOLAND, ID-CNN, SAR-DRN, SAR-BM3D, y FANS, obteniendo resultados mejorados.

En [39] se usan transformadores (conocidos en inglés como transformers), en combinación con un módulo de extracción de características (SFEM de sus siglas en inglés de spatial feature extraction module) para calcular una covarianza cruzada de canales cruzados en el dominio espacial, con el fin de reconstruir la imagen fina, es decir, con énfasis en sus bordes. Los transformadores, los cuales utilizan módulos de atención también son usados en [40], en lo que denominan una red convolucional multi escala con auto atención (SAMSCNN del inglés self-attention multi-scale convolution neural network), la cual mejora los índices y métricas comparados con métodos como PPB (Probabilistic Patch-based), SAR-BM3D y SAR-CNN. En la misma línea de utilizar mecanismos de atención, en [41] se implementa una subred inicial para aprender información relacionada con el ruido y luego otra subred con el mecanismo de atención para realizar la clasificación y extraer características propias de las imágenes SAR.

En [42] se presenta una propuesta, en la cual se utiliza información proveniente de Sentinel 1 nivel GRD y un filtrado utilizando CNN residuales, obteniendo resultados que superan a los filtros de media, Lee, Lee mejorado Fastnl, Kuan, Bilateral, Frost y SAR-BM3D obteniendo un ENL significativamente superior.

Más recientemente se ha encontrado el uso de Autoencoders como técnica de filtrado, ya que su funcionamiento se basa en la compresión (codificación) y descompresión (decodificación) de imágenes,

y una de sus aplicaciones ha sido, además de poder detectar anomalías, reducir el ruido presente en ellas al realizar este proceso descrito. Así, se ven como una herramienta prometedora en el campo de la teledetección, con considerarse como una posible herramienta que presente buen desempeño durante esta tarea, posiblemente haciendo modificaciones en la estructura, profundidad, función de costo y otros parámetros que permitan ajustarse a la naturaleza del ruido speckle.

2.4. Síntesis del estado del arte

La revisión realizada mostró un recorrido, por los filtros clásicos locales, no locales, hasta los más recientes basados en inteligencia artificial, incluyendo aprendizaje de máquina y una subcategoría de este, aprendizaje profundo y autoencoders, basados en redes neuronales convolucionales. Durante la búsqueda realizada en plataformas multidisciplinarias, se utilizaron diversas ecuaciones con el fin de encontrar las publicaciones y calcular el número de ellas encontradas con diferentes rangos de fechas.

En el Cuadro 1 se presenta un resumen de estos resultados con algunos resultados comparativos.

Cuadro 1: Revisión Bibliográfica

ECUACIÓN	CUALQUIER FECHA	2018-2023	VARIACIÓN
speckle AND filter AND SAR AND Lee	17500	6260	36 %
speckle AND filter AND SAR AND local	23200	7880	34 %
speckle AND filter AND SAR AND (nonlocal OR non-local)	3550	2160	61 %
speckle AND filter AND SAR AND "machine learning"	7510	5010	67 %
speckle AND filter AND SAR AND "deep learning"	5050	4420	88 %
speckle AND filter AND SAR AND autoencoder	1180	1080	92 %

Se evidencia, a partir de estos análisis, que unos campos o técnicas que vienen crecientes en los últimos 5 años, mostrando la mayoría (más del 85 %) de sus publicaciones durante este periodo, son la aplicación de técnicas de aprendizaje profundo y autoencoders para el filtrado de imágenes SAR, y en las publicaciones realizadas se encontró que superaron resultados documentados en el estado del arte, incluyendo filtros tradicionales locales y no locales. Aquí se identifica una gran oportunidad de investigación, de la cual parte este trabajo, por lo tanto el aprendizaje de máquina, especialmente modelos de aprendizaje profundo y/o autoencoders, pueden presentar aportes significativos a la ciencia en cuanto es posible que mejoren los resultados hoy disponibles en este filtrado de ruido speckle.

3. Planteamiento del problema

La tecnología de radares de apertura sintética (SAR del inglés Synthetic Aperture Radar) emite radiación electromagnética en frecuencias entre los 300MHz y 300GHz, y posteriormente recibe la señal de retorno ante objetos en la superficie. Este tipo de tecnología se convierte en una fuente de información muy relevante en el campo del monitoreo remoto, puesto que tiene la habilidad de proporcionar datos en alta resolución independientemente de las condiciones ambientales, por lo que es crucial para analizar cobertura terrestre o vegetal y otras aplicaciones de clasificación.

Las imágenes SAR se generan por un radar que se mueve en línea recta, emitiendo la señal electromagnética, la cual viaja a la velocidad de la luz hacia la superficie, luego recibe la señal que rebota o se refleja y su retardo en el tiempo. Por lo tanto, las imágenes de radar resultantes se construyen con la intensidad y el tiempo calculados, lo cual depende principalmente de la aspereza y las propiedades eléctricas de la superficie observada, junto con su distancia al radar en órbita [43].

Estas imágenes, por su naturaleza, poseen un ruido denominado "speckle" que se genera por la iluminación coherente y los mecanismos de retrodispersión. Este tipo de ruido también está presente en imágenes de ultrasonido. Este ruido se caracteriza por poseer un patrón granular que presenta fuertes dificultades de interpretación, y de allí se desprenden más dificultades para las etapas posteriores de aplicaciones de detección de cambios, segmentación o clasificación sobre las imágenes.

Este ruido speckle se modela, a diferencia de otros ruidos, como un ruido multiplicativo, de naturaleza no Gaussiana, lo cual lo convierte en un elemento difícil de remover o reducir. Como producto este ruido, una imagen SAR Y se puede expresar como $Y = f(X, N) = X \cdot N$, donde X es la imagen sin ruido (ground truth) y N es el ruido speckle, el cual se modela según una distribución Gamma Eq. 1:

$$p(N) = \frac{1}{\Gamma(L)} N^L e^{-NL}, \quad (1)$$

donde L es el número de vistas (equivalent number of looks - ENL) de la imagen SAR. Un filtro de speckle ideal removería completamente este ruido, obteniendo la imagen Y , sin introducir artefactos y preservando la información espacial [33].

Así, el filtrado de imágenes SAR es una tarea no trivial, que en la literatura ha requerido de múltiples investigaciones y aún hoy se considera un campo de estudio vigente y abierto. El uso de técnicas de aprendizaje de máquina, y particularmente del aprendizaje profundo, ha empezado a irrumpir como un paradigma que establece una clara división con los métodos tradicionales.

La inteligencia artificial, y muy específicamente el aprendizaje profundo, se han convertido recientemente en herramientas muy útiles para un sinnúmero de aplicaciones como clasificación y segmentación por ejemplo, pero para el caso de filtrado de imágenes, y particularmente de ruido speckle, ha obtenido resultados superiores a los obtenidos por técnicas clásicas como filtros locales y no locales.

Así, se identifica entonces una línea de investigación muy activa en los últimos años y que, la inserción de la inteligencia artificial y los modelos de aprendizaje profundo, será un aporte importante que se puede hacer en este campos de conocimiento, posibilitando futuras aplicaciones en clasificación, segmentación u otras tareas sobre imágenes SAR.

4. Hipótesis

Un método que involucre inteligencia artificial, específicamente de aprendizaje profundo, realizará un filtrado de imágenes de radar de apertura sintética SAR que presente resultados comparativos con otros métodos y enfoques propuestos en la literatura y que, con base en métricas, especialmente de preservación de bordes, se garantice la calidad y medición objetiva y cuantitativa del proceso de filtrado realizado.

5. Objetivos

5.1. Objetivo General

Proponer un método de filtrado de ruido speckle en imágenes de radar de apertura sintética usando estructuras de aprendizaje profundo adaptadas que considere la preservación de bordes como parámetro de convergencia.

5.2. Objetivos Específicos

- Realizar una búsqueda sistemática en el estado del arte con el fin de determinar los protocolos de validación y propuestas que se han implementado en imágenes SAR incluyendo la preservación de bordes.
- Construir un conjunto de datos etiquetado con imágenes SAR que sirva como base para el entrenamiento de modelos de aprendizaje profundo.
- Proponer una estructura de aprendizaje profundo que considere la preservación de bordes dentro del modelo para el proceso de filtrado de ruido speckle
- Validar la estructura propuesta de aprendizaje profundo con base en métricas a partir de un marco de comparación con otros modelos y filtros propuestos en la literatura

6. Metodología

El proyecto inicia, siguiendo el método científico, con una búsqueda sistemática en la literatura, identificando los diferentes protocolos de validación que se realizan, pero muy específicamente enfocado hacia la preservación de bordes, los cuales suministran información muy importante para las aplicaciones que involucran imágenes SAR. Esta búsqueda debe arrojar ideas sobre las diferentes estructuras de

filtros, los conceptos teóricos, matemáticos o estadísticos involucrados en su construcción y las métricas o métodos de validación que se han utilizado.

Posteriormente, dado que se pretende proponer un modelo de aprendizaje profundo, se requiere entonces contar con un conjunto de datos etiquetado, es decir, que contenga tanto imágenes sin ruido como imágenes con ruido speckle, que serán alimentadas al modelo para su entrenamiento. Este conjunto de datos debe construirse preferiblemente con imágenes SAR, evitando el enfoque sintético, pero allí hay algunas limitaciones ya que no existe un conjunto de datos disponible que contenga imágenes SAR e imágenes sin ruido. Por lo tanto allí se deben usar diferentes enfoques documentados en la literatura, como el multilooking, la fusión multitemporal u otro, que permita el diseño de un dataset adecuado. Dentro de este dataset, también se debe considerar el tamaño adecuado de las imágenes, el número de las mismas y el radar y misión que se utilizará.

Específicamente en el modelo, se deben buscar estructuras documentadas que sirvan para el filtrado de ruido, y evaluar si resultarán adecuadas para este ruido particular tipo speckle. Además, dichas estructuras deben ser redefinidas, incluyendo modificación de su función de costo, cantidad de capas ocultas, hiperparámetros, número de épocas y otros elementos que permitan incluir la preservación de bordes como enfoque prioritario del entrenamiento.

Al final, los resultados deben ser validados en comparación con otros filtros, usando métricas estándar o una métrica propuesta, buscando un análisis comparativo y cuantitativo con estos otros modelos, lo que permitirá la generación de resultados concretos que se divulgarán en las revistas especializadas del campo de la geociencia, la inteligencia artificial, teledetección, entre otros.

7. Cronograma

El cronograma completo propuesto con dedicación a tiempo parcial se presenta en el Cuadro 2.

Cuadro 2: Cronograma

ACTIVIDAD	OBJETIVO	SEMESTRE									
		2023-1	2023-2	2024-1	2024-2	2025-1	2025-2	2026-1	2026-2	2027-1	2027-2
Revisión sistemática de literatura	1	X									
Análisis de protocolos de validación	1	X	X								
Conclusiones sobre revisión de literatura	1	X	X								
Búsqueda de plataformas satelitales de descarga de imágenes SAR	2		X	X							
Pre-procesamiento de imágenes SAR descargadas	2		X	X							
Búsqueda de métodos para construcción de conjuntos de datos	2		X	X	X						
Síntesis de métodos para construcción de conjuntos de datos	2			X	X						
Construcción de conjuntos de datos	2			X	X						
Búsqueda de modelos y propuestas para filtrado de ruido speckle con aprendizaje profundo	3				X	X	X				
Síntesis de modelos y propuestas, simulaciones y resultados previos	3					X	X				
Modificación de modelos de forma estructural para incorporar detección de bordes	3					X	X	X			
Análisis de métricas documentadas para validación de modelos y métodos de filtrado	4							X	X		
Definición de modelos para conformar marco de comparación con propuesta	4							X	X	X	X
Aplicación de las validaciones	4								X	X	X
Análisis de marco comparativo y experimentos realizados	4								X	X	X
Construcción y realización de ponencia	1 al 4					X	X	X			
Redacción y publicación de artículos en revistas indexadas	1 al 4	X	X	X	X	X	X	X	X	X	X
Realización de pasantía	1 al 4				X						

8. Recursos requeridos

- Computador portátil con Matlab y Python 3.7 o superior con librerías: Tensorflow, Scikit-learn, OpenCV, Scikit-image, Theano, Pytorch y Keras.
- Cuenta de Google con unidades de cómputo para entrenamiento de modelos en Colab (<https://colab.research.google.com/>).

9. Resultados esperados

De los objetivos y del desarrollo del proyecto, se esperan los siguientes resultados, los cuales apuntan a una tesis por compendio según las normas de la ULPGC:

- 1 Artículo científico mínimo categoría Q2 enfocado en el proceso para diseñar el conjunto de datos (dataset).
- 2 Artículos científicos mínimo categoría Q2 enfocados en las propuestas de modelos y estructuras de aprendizaje profundo, incluyendo validación y comparativo con otras propuestas.
- 1 Ponencia en evento internacional con resultados derivados de los objetivos.

Referencias

- [1] Aiyeola Sikiru Yommy, Rongke Liu, and Shuang Wu. Sar image despeckling using refined lee filter. In *2015 7th International Conference on Intelligent Human-Machine Systems and Cybernetics*, volume 2, pages 260–265, 2015.
- [2] Viviana E. Ferraggine and Sebastián Aldo Villar. A robust version of the Lee filter for speckle reduction and contrast enhancement applied to side scan sonar images. *2020 IEEE Congreso Biental de Argentina (ARGENCON)*, pages 1–6, 2020.
- [3] Deepika Hazarika, Vijay Kumar Nath, and Manabendra Bhuyan. A lapped transform domain enhanced lee filter with edge detection for speckle noise reduction in SAR images. *2015 IEEE 2nd International Conference on Recent Trends in Information Systems (ReTIS)*, pages 243–248, 2015.
- [4] Jong-Sen Lee, Jen-Hung Wen, Thomas L. Ainsworth, Kun Shan Chen, and Abel J. Chen. Improved sigma filter for speckle filtering of SAR imagery. *IEEE Transactions on Geoscience and Remote Sensing*, 47:202–213, 2009.
- [5] Jun Ling Zhu, Jianguo Wen, and Yafeng Zhang. A new algorithm for SAR image despeckling using an enhanced Lee filter and median filter. *2013 6th International Congress on Image and Signal Processing (CISP)*, 01:224–228, 2013.
- [6] Hua Zhong, Lu Lu, Jingjing Zhang, Shuang Wang, and Xiaojin Hou. Nonlocal-Lee filter for SAR image despeckling based on hybrid patch similarity. *2013 IEEE International Geoscience and Remote Sensing Symposium - IGARSS*, pages 1987–1990, 2013.
- [7] Lang Fengka. An adaptive enhanced lee speckle filter for polarimetric SAR image. 2014.
- [8] Sriparna Banerjee, Sheli Sinha Chaudhuri, Raghav Mehra, and Arundhati Misra. A comprehensive survey on frost filter and its proposed variants. In *2020 5th International Conference on Communication and Electronics Systems (ICCES)*, pages 109–114, 2020.
- [9] Oleg Yu. Ivanov and Andrey Sosnovsky. Modification of the frost speckle-noise filter for solving problems of radar data processing. *INTERNATIONAL CONFERENCE OF NUMERICAL ANALYSIS AND APPLIED MATHEMATICS ICNAAM 2020*, 2022.
- [10] Jiamu Li, Wenbo Yu, Yi Wang, Zijian Wang, Jiarong Xiao, Zhongjun Yu, and Desheng Zhang. Guidance-aided triple-adaptive frost filter for speckle suppression in the synthetic aperture radar image. *Remote. Sens.*, 15:551, 2023.
- [11] Ranjith Kumar Painam and M. Suchetha. Despeckling of SAR images using bemd-based adaptive frost filter. *Journal of the Indian Society of Remote Sensing*, pages 1 – 12, 2022.
- [12] Sriparna Banerjee, Sheli Sinha Chaudhuri, Raghav Mehra, and Arundhati Bagchi Misra. A comprehensive survey on frost filter and its proposed variants. *2020 5th International Conference on Communication and Electronics Systems (ICCES)*, pages 109–114, 2020.

- [13] Hui Li and Xu-Liang Duan. Sar ship image speckle noise suppression algorithm based on adaptive bilateral filter. *Wireless Communications and Mobile Computing*, 2022.
- [14] Aafreen Alam. Reduction of speckle noise in SAR images with hybrid wavelet filter. *International Journal for Research in Applied Science and Engineering Technology*, 2022.
- [15] Xigang Wang, Zhiguo Meng, Si Chen, Zhuangzhuang Feng, Xinbiao Li, Tianhao Guo, Chunmei Wang, and Xingming Zheng. A block-scale fft filter based on spatial autocorrelation features of speckle noise in SAR image. *Remote. Sens.*, 15:247, 2022.
- [16] Raul Castaneda, Jorge I. Garcia-Sucerquia, and Ana Doblas. Speckle noise reduction in coherent imaging systems via hybrid median–mean filter. *Optical Engineering*, 60:123107 – 123107, 2021.
- [17] Antoni Buades, Bartomeu Coll, and Jean-Michel Morel. Non-local means denoising. *Image Processing Online*, 1, 2011.
- [18] Yongjian Yu and Scott T. Acton. Speckle reducing anisotropic diffusion. *IEEE transactions on image processing : a publication of the IEEE Signal Processing Society*, 11 11:1260–70, 2002.
- [19] Sara Parrilli, Mariana Poderico, Cesario Vincenzo Angelino, and Luisa Verdoliva. A nonlocal SAR image denoising algorithm based on llmse wavelet shrinkage. *IEEE Transactions on Geoscience and Remote Sensing*, 50:606–616, 2012.
- [20] Chao Wang, Bao-Long Guo, and Fangliang He. A novel SAR image despeckling method based on local filter with nonlocal preprocessing. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 16:2915–2930, 2023.
- [21] Chao Wang and Bao-Long Guo. A double residual iterative regularization method for SAR image despeckling. *IEEE Geoscience and Remote Sensing Letters*, 20:1–5, 2023.
- [22] Débora Chan, Juliana Gambini, and Alejandro César Frery. Entropy-based non-local means filter for single-look SAR speckle reduction. *Remote. Sens.*, 14:509, 2022.
- [23] Soumaya Fatnassi, Mohamed Yahia, Tarig Ali, and Mohammad Maruf Mortula. Sar speckle filtering using hybrid nonlocal sigma filter. *2021 18th International Multi-Conference on Systems, Signals & Devices (SSD)*, pages 463–467, 2021.
- [24] Luis Gómez, Jie Wu, and Alejandro César Frery. Non-local means filters for full polarimetric synthetic aperture radar images with stochastic distances. *Image Process. Line*, 12:142–172, 2022.
- [25] Jie Wu, Luís Gómez Déniz, and Alejandro César Frery. A non-local means filters for SAR speckle reduction with likelihood ratio test. *IGARSS 2022 - 2022 IEEE International Geoscience and Remote Sensing Symposium*, pages 2319–2322, 2022.
- [26] Ramin Farhadiani, Saeid Homayouni, and Abdolreza Safari. Hybrid SAR speckle reduction using complex wavelet shrinkage and non-local pca-based filtering. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 12:1489–1496, 2019.
- [27] Aiyeola Sikiru Yommy, Rongke Liu, Spencer O. Onuh, and Ani Cosmas Ikechukwu. Sar image despeckling and compression using k-nearest neighbour based lee filter and wavelet. *2015 8th International Congress on Image and Signal Processing (CISP)*, pages 158–167, 2015.
- [28] Ian J. Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron C. Courville, and Yoshua Bengio. Generative adversarial nets. In *NIPS*, 2014.
- [29] Giovanni Chierchia, Davide Cozzolino, Giovanni Poggi, and Luisa Verdoliva. Sar image despeckling through convolutional neural networks. In *2017 IEEE International Geoscience and Remote Sensing Symposium (IGARSS)*, pages 5438–5441. IEEE, 2017.
- [30] Xiangli Yang, Loïc Denis, Florence Tupin, and Wen Yang. Sar image despeckling using pre-trained convolutional neural network models. *2019 Joint Urban Remote Sensing Event (JURSE)*, pages 1–4, 2019.

- [31] Dong-Xiao Yue, Feng Xu, and Yaqiu Jin. Sar despeckling neural network with logarithmic convolutional product model. *International Journal of Remote Sensing*, 39:7483 – 7505, 2018.
- [32] Qiang Zhang, Qiangqiang Yuan, Jie Li, Z. Yang, and Xiaoshuang Ma. Learning a dilated residual network for SAR image despeckling. *ArXiv*, abs/1709.02898, 2017.
- [33] Sergio Vitale, Giampaolo Ferraioli, and Vito Pascazio. A new ratio image based cnn algorithm for SAR despeckling. *IGARSS 2019 - 2019 IEEE International Geoscience and Remote Sensing Symposium*, pages 9494–9497, 2019.
- [34] Davide Cozzolino, Luisa Verdoliva, Giuseppe Scarpa, and Giovanni Poggi. Nonlocal SAR image despeckling by convolutional neural networks. *IGARSS 2019 - 2019 IEEE International Geoscience and Remote Sensing Symposium*, pages 5117–5120, 2019.
- [35] Huanfeng Shen, Chen Zhou, Jie Li, and Qiangqiang Yuan. Sar image despeckling employing a recursive deep cnn prior. *IEEE Trans. Geosci. Remote. Sens.*, 59:273–286, 2021.
- [36] Yuanyuan Zhou, Jun Shi, Xiaqing Valerie Yang, Chen Wang, Durga Priya Kumar, Shunjun Wei, and Xiaoling Zhang. Deep multi-scale recurrent network for synthetic aperture radar images despeckling. *Remote. Sens.*, 11:2462, 2019.
- [37] Praveen Ravirathinam, Darshan R Agrawal, and J. Jennifer Ranjani. Neighcnn: A cnn based SAR speckle reduction using feature preserving loss function. *ArXiv*, abs/2108.11573, 2021.
- [38] Sergio Vitale, Giampaolo Ferraioli, and Vito Pascazio. Multi-objective cnn-based algorithm for SAR despeckling. *IEEE Transactions on Geoscience and Remote Sensing*, 59:9336–9349, 2020.
- [39] Yuxu Lu, Yu Guo, R. W. Liu, Kwok Tai Chui, and Brij Bhooshan Gupta. Graddt: Gradient-guided despeckling transformer for industrial imaging sensors. *IEEE Transactions on Industrial Informatics*, 19:2238–2248, 2023.
- [40] Zhiqing Wen, Yi He, Sheng Yao, Wang Yang, and Lifeng Zhang. A self-attention multi-scale convolutional neural network method for SAR image despeckling. *International Journal of Remote Sensing*, 44:902 – 923, 2023.
- [41] Lin Zou, Xi Wang, Xue lian Yu, Haohao Ren, Yun Zhou, and Xue gang Wang. Synthetic aperture radar target recognition via deep attention convolutional network assisted by multiscale residual despeckling network. *Journal of Applied Remote Sensing*, 17:016502 – 016502, 2023.
- [42] Alessandro Sebastianelli, Maria Pia del Rosso, Silvia Liberata Ullo, and Paolo Gamba. A speckle filter for sentinel-1 SAR ground range detected data based on residual convolutional neural networks. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing*, 15:5086–5101, 2021.
- [43] NASA. Get to know SAR - overview, 2020. Accessed on March 24, 2023.